

01 / 연구 질문과 새 시작

4언어 표현 선택 · 학습 이력 · 어휘 관계 | v4.0.0 | 2026.09.14

학습 이력은 다국어 표현 선택을 예측하는가?

한국어를 먼저 학습한 시가 영어·중국어·프랑스어를 추가로 배울 때, 표현할 수 있는 능력과 실제 선택을 분리하고 어원·표기·토큰 관계를 함께 검증한다.

핵심 문제와 범위

다른 언어의 표현이 먼저 출력됐다고 기존 표현을 잊었다고 볼 수 없다. 요청하면 각 언어로 답할 수 있는지와, 요청 언어가 없을 때 어떤 등록 표현을 선택하는지를 따로 관측한다. 이번 실험은 일반적인 외국어 숙달이나 사람의 생각을 측정하지 않는다.

언어 습득 이력과 코드스위칭을 연결하는 계산 연구가 이미 있다[R10]. 이번 기여 후보는 단순 언어 혼합 발견이 아니라, 통제된 추가 노출 이력과 어휘 관계가 미관측 개념의 선택 변화를 예측하는지에 있다. 파일럿에서 신규성이나 효과를 미리 확정하지 않는다.

고정하는 것과 하지 않는 것

유지	이번 파일럿에서 검증	후속 단계로 남김
한국어 → 영어 → 중국어 → 프랑스어	실제 4언어 의미 대응·어원 근거·공유 표현 비중	인간 기억 원리·교육효과 검증
독립 초기화 4개, 같은 모델 계보	요청 산출, 자유 선택, 측정 재현성, 일정 대조	대형 모델 전이·모든 언어 순열
어원 / 표기 / 토큰의 분리	EN-FR 추가 노출 순서의 효과와 집단별 기술 분석	복습 최적화·교정 정책·내부 패칭

에듀테크 연결의 위치

장기 목표는 원하는 언어의 표현을 꺼내기 어려운 상태를 예측하는 학습 시다. 이번에는 AI의 통제 실험으로 가설과 측정 수단을 검증한다. 실제 학습자 로그가 없다는 이유로 이 파일럿을 막지 않지만, AI 실험의 성공을 사람에게 효과적인 연습법이라고 해석하지 않는다.

표기와 권한

[F] 출처가 명시한 사실 · [D] 본연구 설계 · [H] 미검증 가설 · [R] 실제 로그로 확인한 값 · [U] 사용자 보고. 문서의 수량·임계값은 별도 표시가 없으면 [D]다. 이번 v4는 조건부 제한 파일럿을 허용하며, 본시험은 비활성이다. 과거 패키지·모델·보고서를 재사용하지 않는다.

02 / 데이터와 어원 검증

학습 전에 확정할 원천·의미·표현·증거

원천 [F]	사용 목적	접근과 검증의 한계
국립국어원 사전 API [R1]	같은 한국어 의미의 EN/ZH/FR 표현·정의 연결	인증키 또는 적절한 원본 스냅샷 필요. 번역 결측·다의어는 실제 응답으로 확인.
Wiki40B/ko [R2]	한국어 초기 corpus와 KO-only tokenizer	공식 train split·원자료 조건·hash 고정. 원천이 한국어라고 외국어 문자열이 전혀 없다는 뜻은 아님.
Wiktextextract / Kaikki [R3]	어원·차용 경로의 검수 근거 후보	sense 연결과 출처를 사람이 확인. 자동 추출문이나 LLM 설명을 검증 어원으로 취급하지 않음.

의미 정렬과 등록 표현 [D]

연구 개념 ID는 snapshot + target_code + sense_order다. 네 언어의 실제 표현·뜻풀이를 원문과 대조하여 **언어당 등록 표현 1개**를 고정한다. 대안 표현은 보존하되 결과를 보고 정답에 추가하지 않는다. API 수집 완료는 검수 완료가 아니다. NFC·공백 정리만 기본 적용한다. 악센트·간체/번체·병음을 자동 통합하지 않는다. 같은 문자열이 두 언어에 쓰이면 공유 표현으로 남긴다. 언어별 선택이 식별되는 집단과 공유 집단의 포함·제외·미확인 비율을 모두 보고한다.

어원과 형태를 분리하는 방법 [D]

변수	정의와 처리
역사적 관계	차용 확인 / 공유 원천 확인 / 검토 범위에서 별도 경로 / 미확인. 근거 URL·원본 hash·sense·역사 범위·검수자를 기록.
표기 유사성	NFC 문자 편집거리로 1 - 거리 / 최대 길이. 어원이나 발음의 대응으로 쓰지 않음.
토큰 유사성	실제 frozen tokenizer의 표현-only token Jaccard와 길이. 지시·padding·종료 토큰 제외.
주분석 / 한계	EN-FR을 우선 검수. KO-ZH 등 미검수 쌍은 미확인으로 유지. 어원과 형태가 분리되지 않으면 독립 어원 기여를 주장하지 않음.

자료 gate [D] 60개 검수 개념, 4언어 식별 개념 40개 이상, 그 안의 EN-FR 관련표현 12개 및 검토된 별도 경로 12개 이상. 이는 검정력 수치가 아니라 파일럿 최소 운영안이다. 미달하면 자료 확보를 먼저 해결하며 두 언어로 축소하지 않는다.

검색어 목록은 수집용 설계 목록이며 대표 표본이나 표준 benchmark가 아니다. 의미·어원 검수 승인 전 학습 금지. 합성 시험 데이터를 실제 학습 자료로 쓰지 않는다.

03 / 실험 방법 1/2

순차 습득 관측과 습득 후 일정 대조를 구분한다

S. 한국어 기반 형성 후 외국어를 순차 추가

각 독립 root: random INIT → KO corpus/lexical(T0) → EN 추가(T1) → ZH 추가(T2) → FR 추가(T3). 3언어 시점 T2와 4언어 시점 T3를 모두 보존한다. 준비 weights를 복제한 반복은 독립 초기화가 아니다.

초기 설계는 GPT2형 10층·폭512·8head, context256, vocab16384, dropout0. KO train에서만 학습한 byte-level BPE를 고정한다. 실제 파라미터·버전·정밀도·토큰 수를 기록한다. corpus는 최대 200만 model tokens, 각 lexical 단계는 고정 3,000 updates이며 성능 보장이 아니다.

새 언어 target 1/2 + 기존 언어 합계 1/2을 배정하고 active 입력언어와 ANY/requested를 균형화한다. 복습 비율·업데이트·언어 수가 함께 바뀌므로 S는 recipe 변화의 관측이지 순수 언어 수 효과가 아니다. best dev 대신 고정 단계 종점으로 평가한다.

H. 이미 배운 EN-FR 표현의 추가 노출 순서

구간	A / B 조작과 통제
Mutable 72 round	개념 pair에 $g=+1/-1$ 을 무작위 배정. A에서 한쪽은 EN36→FR36, 다른 쪽은 역순. B에서는 각각 반대로.
고정 anchor	Mutable 2round마다 KO 1round와 ZH 1round를 동일하게 삽입. 두 anchor 언어 각 36회.
공통 tail	4cycles × (KO, EN, ZH, FR). 각 언어 최종 40회, 개념당 160회. 60개면 branch당 9,600 target 예시.

A/B의 실제 record 내용 전체, 입력·출력·지시별 횟수, anchor/tail, 마지막 target optimizer step, 전체 update 수를 검사한다. round와 update는 다르다. 길이·유효 token 차이와 입력에 우연히 나타난 표현도 기록한다. lexical loss는 예시별 response 평균 후 batch 평균이다.

T3의 model·optimizer·RNG·loader·누적 위치를 모두 복구하고 공통 LR 변환 후 분기한다. 같은 GPU에서 동일 10step A/A'와 연속실행 대 resume를 대조한다[R7]. CPU 수식시험만으로 GPU 재현성을 통과 처리하지 않는다.

해석 범위: 공유 모델에 배정된 전체 일정의 효과다. 첫 외국어 도입 순서, 특정 단어의 독립 직접효과, 어원의 인과효과가 아니다. B36 하나의 파일럿만으로 다양한 학습 이력에 대한 예측 일반화를 주장하지 않는다.

04 / 실험 방법 2/2 · 평가

근거 방법 [F]와 연구 지표 [D]를 구분한다

지표	정의와 선행 근거
등록 산출 S / A / C	[R4]의 reverse-dictionary-greedy 첫줄 일치를 확장. S는 등록표현 일치, A는 요청 언어와 양립, C는 등록된 다른 언어 표현. 등록 밖 응답은 별도 보존하며 의미 오류·망각으로 단정하지 않음.
확률 질량 Z / 선택 Q	[R5]의 continuation likelihood를 참고. 전체 canonical 답+종료기호를 점수화한다. 공유 문자열을 한 사건으로 합친 Q/Z는 본연구 정의이며 첫 토큰·길이 정규화 확률이 아님.
신뢰도	[R6]의 Spearman + wrapper 절대차, Q의 분산·범위·동률·Z. 하나의 수치만으로 전체 측정 타당성을 판단하지 않음.
예측 / 능력 유지	MAE는 표준 오차[R9]. 본시험 target은 이력 차이 벡터. 능력 동등성은 TOST[R8]로 검사하며 비유의성을 동등성으로 바꾸지 않음.

$p(y) = P(\text{canonical tokens}(y + \text{newline}) \mid \text{prefix}, \text{ANY})$

Z = 서로 다른 등록 표현 y의 $p(y)$ 합

$Q_M = \text{membership}(y) = M$ 인 $p(y)$ 의 합 / Z

공유 표현은 언어별로 중복 합산하지 않는다. 네 언어가 구분되는 코호트에만 완전한 Q_i 벡터를 정의한다. 공유군은 membership 질량으로 따로 보고한다. 낮은 Z에서 높은 Q가 나올 수 있으므로 raw $p \cdot \log Z$ ·생성 S/A를 반드시 함께 제시한다. 모든 단계의 후보 universe는 네 언어로 고정한다.

주효과와 파일럿 측정 gate [D]

$h_{s,c,l} = g_{s,c} (Q_l^A - Q_l^B)$, 언어별 h의 합=0.

EN-FR 대비 $r = (h_{fr} - h_{en})/2$. root별 효과, 개념 변동, 어원 집단 대비를 보고한다. 어원은 비무작위 속성이므로 집단 차이를 역사적 원인으로 단정하지 않는다.

T3/KO/RD/dev에서 요청언어별 A가 각각 0.90 이상이어야 한다. 같은 checkpoint·root·개념집합에서 dev1/dev2를 정렬하여 언어별 rho와 절대차를 계산한다. 어느 언어든 $\rho < 0.60$ 또는 undefined, 절대차 > 0.15 , 어느 wrapper든 $Z < 0.05$ 비율이 10% 이상이면 측정 경고로 H를 차단한다. 모두 설계 경고선이며 보편적 기준이 아니다.

분할·불확실성과 미래 예측 검증

독립 단위는 root 초기화다. wrapper-평가 행을 독립 학습 반복으로 세지 않는다. seed 간/개념 간 변동과 split-half 재현성을 구분하며 MAE를 상관으로 나누지 않는다. 향후 초기 편향·최근성 비교군, 이력, 형태, 어원, 상호작용을 같은 회귀기로 비교한다. 어원 family·동어의 cluster를 분리하고 새 개념·새 일정·새 root 성능을 각각 보고한다. 60개 파일럿의 예측 우월성은 확인적으로 판정하지 않는다.

05 / 실행 순서와 판정

잘못된 실행의 재발을 막는 최소 운영 규칙

순서	통과 조건 / 멈추는 조건
1. 새 시작	전달 해시·CPU 시험 → API 키/적법한 스냅샷. 키 없으면 요청 0회로 차단. 구버전 실행 감사는 하지 않음.
2. 자료와 코드	네 언어 의미·어원 검수, 고정 cohort와 config hash, 실제 tokenizer/scorer/전체 상태 재현성 시험. 합성 자료로 승인 대체 금지.
3. 첫 root	독립 INIT부터 T0~T3 실행. 준비·측정 미달이면 S 자료와 실패를 보존하고 다른 roots/H 확대 금지.
4. 제한 파일럿	나머지 예정 roots도 독립 학습. 모두 T3 gate 통과 후 H. 원본 평가→단일 JSON→표·markdown·판정. main은 비활성.

예산 [D/U]: campaign 24 GPUh, root당 6 GPUh 상한. 이전 0.953 GPUh는 사용자 보고 누계로 분리 기입하고 같은 campaign에서 차감한다. 두 GPU의 동시 사용 시간은 합산한다. 새 폴더라도 비용을 몰래 0으로 초기화하지 않는다. 실제 비용·최대 VRAM과 중단 상태를 기록한다.

현재 검증 [R]: CPU 시험 65개 통과(작은 PyTorch 모델의 상태 복구 시험 포함). 실제 사전 payload·의미·어원 QA·완성 trainer·원격 GPU 학습은 미완료다. 작업 환경의 HTTP 시도는 DNS 오류로 실패했다. 이 ZIP은 새 구현과 실행을 위한 명세·참조 도구이며 학습 결과가 아니다.

핵심 출처 · 클릭 가능한 원문

[R1] 국립국어원 Open API / 인증

[R2] Wiki40B 공식 TFDS 데이터 문서

[R3] Kaikki raw / Wikitextract (Ylonen, 2022)

[R4] Xu et al. (2024), On the Tip of the Tongue, §2.1

[R5] EleutherAI lm-evaluation-harness

[R6] SciPy spearmanr 공식 문서

[R7] PyTorch Reproducibility (고정 v2.8 참고)

[R8] Lakens (2017), Equivalence Tests: A Practical Primer

[R9] scikit-learn mean_absolute_error

[R10] Tsoukala et al. (2021), Simulating Code-switching

출처의 기능·방법과 본연구 설계의 차이는 docs/SOURCES_KO.md에 상세히 명시했다. 문서 확인만으로 실제 데이터 접근·완전 교집합·어원 진위를 보장하지 않는다.